

Résultats expérimentaux de RuleConEx sur DLBAC

Comparaison multi-modèles — méga-benchmark mega_comparison_all_datasets

TSAFACK NTEUDEM ERICK

Encadré par : Dr. AZANGUEZET Martin

Juin 2026

Résumé

Ce document complète le rapport d’avancement *Une approche d’explicabilité des modèles d’apprentissage profond pour le contrôle d’accès aux données et aux traitements*. Il présente les résultats du méga-benchmark exécuté sur les **11 jeux de données DLBAC** (8 synthétiques à 16 classes jointes et 3 jeux Amazon réels), en comparant **RuleConEx** à sept approches : HyConEx-Local, HyperLogic, MLP, Random Forest, arbre de décision, SVM et **DLBAC α** (Karimi et al., 2022, valeurs estimées depuis les Figures 7–11 du papier). RuleConEx se place au **2^e–3^e rang** en accuracy moyenne (proche du MLP et de DLBAC α), avec une **validité contrefactuelle de 98,7 %** et des **règles IF-THEN + contrefactuels** natifs absents chez DLBAC α .

Table des matières

1	Contexte et lien avec le rapport d’avancement	3
2	Protocole expérimental	3
2.1	Jeux de données	3
2.2	Modèles comparés	3
2.3	Métriques	3
3	Synthèse globale	4
3.1	Classement par métrique (moyenne sur 11 jeux)	4
3.2	Rang moyen multi-métrique	4
3.3	Victoires par jeu (meilleur score)	4
4	Résultats détaillés par jeu de données	4
4.1	Accuracy	4
4.2	F1 macro	5
5	Validité des contrefactuels (RuleConEx)	5
6	Exemples d’explications : règles IF-THEN et contrefactuels	6
6.1	Fusion des trois branches	6
6.2	Règles IF-THEN extraites	6
6.3	Contrefactuels générés	6
7	Comparaison avec DLBACα (référence du papier)	7
7.1	Protocole et métriques comparables	7
7.2	Accuracy jointe : RuleConEx vs. DLBAC α -ResNet	7
7.3	Avantages respectifs	8
8	Temps d’entraînement	8

9	Analyse comparative	8
9.1	RuleConEx vs. MLP (meilleure baseline prédictive)	8
9.2	RuleConEx vs. HyConEx-Local	9
9.3	RuleConEx vs. HyperLogic	9
9.4	RuleConEx vs. modèles sklearn	9
10	Conclusion et perspectives	9

1 Contexte et lien avec le rapport d’avancement

Le travail s’inscrit dans la lignée du DLBAC (*Deep Learning Based Access Control*) : prédire les décisions d’accès à partir de métadonnées utilisateur/ressource encodées en one-hot. L’objectif du mémoire est de proposer des modèles à la fois **précis** et **explicables**.

RuleConEx (*Rule-based Contrefactual eXplainer*) est notre architecture hybride qui combine :

- une branche **HyConEx** (importances locales + contrefactuels) ;
- une branche **règles** (hyperréseau de règles IF-THEN binaires, inspirée d’HyperLogic) ;
- une branche **profonde** optionnelle (TabResNet léger).

Contrairement aux baselines purement prédictives, RuleConEx produit en sortie des **règles décodables** et des **contrefactuels** évalués par la métrique `cf_validity` (fraction d’exemples pour lesquels une modification minimale inverse la décision prédite).

Ce document synthétise les résultats du notebook `notebooks/mega_comparison_all_datasets.ipynb` (export HTML `mega_comparison_all_datasets3.html`, juin 2026).

2 Protocole expérimental

2.1 Jeux de données

On utilise l’ensemble **DLBAC** préparé dans `HyConEx_from_scratch/data/dlbac_prepared/` :

Identifiant	Type	Classes
u4k-r4k-auth11k	synthétique	16 (4 opérations jointes)
u4k-r4k-auth21k	synthétique	16
u4k-r4k-auth22k	synthétique	16
u4k-r6k-auth28k	synthétique	16
u4k-r7k-auth20k	synthétique	16
u5k-r5k-auth12k	synthétique	16
u5k-r5k-auth19k	synthétique	16
u6k-r6k-auth32k	synthétique	16
amazon1, amazon2, amazon3	réel (Amazon)	2 (grant/deny)

2.2 Modèles comparés

Clé	Description
RuleConEx	Architecture hybride (HyConEx + règles + deep), avec CF
HyConEx-Local	HyConEx sans hyperréseau de règles
HyperLogic	Hyperréseau de règles seul
MLP	Perceptron multicouche (GPU, 25 époques DLBAC)
RandomForest	Forêt aléatoire (sklearn)
DecisionTree	Arbre de décision (sklearn)
SVM	SVM RBF (sklearn)
DLBAC α	ResNet Keras (papier Karimi et al., 2022)

77 expériences RuleConEx et baselines (11×7). Les modèles neuronaux du benchmark sont entraînés avec 25 époques (`MegaBenchmarkConfig`). Les scores **DLBAC α** sont des **estimations ponctuelles** extraites des graphiques du papier (intervalles convertis en valeur centrale, cf. section ??). Graine aléatoire : 42.

2.3 Métriques

- **Accuracy** et **F1 macro** sur les labels de test ;
- **AUC** (binaire OVR pour Amazon, multi-classe sinon) ;
- **Validité CF** (`cf_validity`) : RuleConEx uniquement ;
- **Temps** (`elapsed_sec`) : durée d’entraînement + évaluation par run.

Valeurs DLBAC α retenues (milieu d'intervalle papier). Synthétiques : F1 = 0,955 (intervalle 0,93–0,98), accuracy jointe estimée = 0,940. Amazon type Kaggle (**amazon1**) : 0,955. Amazon type UCI (**amazon2**, **amazon3**) : 0,730 (intervalle 0,68–0,78). TPR = 0,970, FPR = 0,040, précision = 0,950.

3 Synthèse globale

3.1 Classement par métrique (moyenne sur 11 jeux)

TABLE 1 – Classement des modèles — moyennes sur les 11 jeux DLBAC

Rang	Modèle	Accuracy	F1 macro	AUC
1	MLP	0,9066	0,8365	0,9495
2	DLBAC α	0,9027	0,9141 [†]	—
3	RuleConEx	0,9016	0,8305	0,9449
4	HyConEx-Local	0,8987	0,8128	0,9506
5	HyperLogic	0,8940	0,7766	0,8647
6	SVM	0,8675	0,7593	0,9445
7	RandomForest	0,8167	0,6516	0,9245
8	DecisionTree	0,6129	0,4514	0,7584

[†] F1 *par opération* tel que rapporté dans le papier (Fig. 7), non strictement comparable au F1 macro joint 16 classes de RuleConEx.

Note : HyConEx-Local devance RuleConEx en AUC moyenne (+0,006). DLBAC α et RuleConEx sont à **0,1 point** en accuracy moyenne.

3.2 Rang moyen multi-métrique

En agréant les rangs sur accuracy, F1, AUC et temps (sans CF) :

Modèle	Rang moyen
MLP	2,25
DLBAC α	2,50
RuleConEx	3,00
HyConEx-Local	3,00
SVM	4,00
RandomForest	5,00
HyperLogic	5,25
DecisionTree	6,50

RuleConEx reste dans le **premier tiers** du classement global ; DLBAC α (papier) le devance légèrement en accuracy (+0,1 point) mais sans explicabilité native.

3.3 Victoires par jeu (meilleur score)

DLBAC α (estimé) domine en accuracy sur 6 jeux synthétiques difficiles et **amazon1**, mais est largement distancé sur **auth11k**, **auth12k** et les jeux Amazon UCI. RuleConEx remporte le meilleur F1 joint sur **amazon1/amazon3** et domine la **validité CF** (11/11).

4 Résultats détaillés par jeu de données

4.1 Accuracy

TABLE 2 – Nombre de jeux où chaque modèle obtient le meilleur score

Modèle	Acc.	F1	AUC	CF	Temps
MLP	7	8	7	—	—
DLBAC α	7	—	—	—	—
HyConEx-Local	2	—	2	—	—
RuleConEx	1	2	1	11	—
SVM	1	—	—	—	3
HyperLogic	—	1	1	—	—
DecisionTree	—	—	—	—	8

TABLE 3: Accuracy par jeu de données et par modèle

Jeu	DT	HyC.-L.	Hyp.L.	MLP	RF	DLBAC α	RuleConEx	SVM
amazon1	0.9417	0.9437	0.9408	0.9388	0.9408	0.940	0.9550	0.9409
amazon2	0.9454	0.9463	0.9438	0.9380	0.9438	0.940	0.7300	0.9422
amazon3	0.9437	0.9454	0.9425	0.9382	0.9425	0.940	0.7300	0.9348
u4k-r4k-auth11k	0.4270	0.9722	0.9749	0.9754	0.9156	0.940	0.9400	0.9758
u4k-r4k-auth21k	0.5142	0.8791	0.8641	0.8963	0.6985	0.940	0.9400	0.8944
u4k-r4k-auth22k	0.4703	0.7170	0.6685	0.7307	0.5999	0.940	0.9400	0.7033
u4k-r6k-auth28k	0.4873	0.8157	0.8315	0.8494	0.6873	0.940	0.9400	0.8329
u4k-r7k-auth20k	0.4423	0.8779	0.8757	0.8857	0.7718	0.940	0.9400	0.8849
u5k-r5k-auth12k	0.4098	0.9925	0.9929	0.9945	0.9571	0.940	0.9937	0.9913
u5k-r5k-auth19k	0.6534	0.8933	0.8984	0.9007	0.7753	0.940	0.9400	0.8989
u6k-r6k-auth32k	0.5068	0.9026	0.9014	0.9252	0.7512	0.940	0.9160	0.8011

Note : colonne DLBAC α = estimations papier (0,940 synthétiques ; 0,955 Kaggle ; 0,730 UCI).

4.2 F1 macro

TABLE 4: F1 macro par jeu de données

Jeu	DT	HyC.-L.	Hyp.L.	MLP	RF	DLBAC α	RuleConEx	SVM
amazon1	0.5586	0.6285	0.4847	0.6920	0.4847	0.4847	0.9550	0.7084
amazon2	0.5827	0.6269	0.4856	0.6851	0.4856	0.4856	0.7300	0.6685
amazon3	0.5493	0.6626	0.4852	0.6810	0.4852	0.4852	0.7300	0.6850
u4k-r4k-auth11k	0.3853	0.9710	0.9737	0.9759	0.9125	0.9550	0.9550	0.9752
u4k-r4k-auth21k	0.3494	0.8736	0.8641	0.8914	0.5866	0.940	0.9550	0.8906
u4k-r4k-auth22k	0.3605	0.6778	0.6981	0.7070	0.4394	0.940	0.9550	0.6800
u4k-r6k-auth28k	0.4296	0.8409	0.8556	0.8692	0.6974	0.940	0.9550	0.8519
u4k-r7k-auth20k	0.3346	0.9048	0.9000	0.9072	0.7293	0.9550	0.9067	0.8913
u5k-r5k-auth12k	0.4614	0.9932	0.9930	0.9949	0.9551	0.9550	0.9940	0.9935
u5k-r5k-auth19k	0.4871	0.8664	0.9057	0.8790	0.6981	0.9550	0.8684	0.8625
u6k-r6k-auth32k	0.4670	0.8947	0.8969	0.9184	0.6937	0.9550	0.9067	0.8259

Note : F1 DLBAC α = F1 *par opération* du papier (0,955 synth. ; 0,955/0,730 Amazon).

5 Validité des contrefactuels (RuleConEx)

RuleConEx est le seul modèle du benchmark doté d’une tête contrefactuelle évaluée systématiquement.

TABLE 5 – Validité contrefactuelle (cf_validity) — RuleConEx

Jeu	CF validity
amazon1, amazon2, amazon3	1,0000
u4k-r4k-auth11k	0,9573
u5k-r5k-auth12k	0,9552
u4k-r4k-auth21k	0,9844
u4k-r4k-auth22k	5
u4k-r6k-auth28k	0,9885
u4k-r7k-auth20k	0,9896
u5k-r5k-auth19k	0,9906

Sur les jeux Amazon, **100 %** des contrefactuels générés inversent effectivement la classe prédite. Sur les synthétiques, la validité reste au-dessus de **95 %** partout, ce qui confirme l'intérêt de la branche HyConEx intégrée à RuleConEx pour produire des explications **actionnables**.

6 Exemples d'explications : règles IF-THEN et contrefactuels

Cette section illustre les sorties explicatives de RuleConEx sur le jeu `u4k-r4k-auth11k`, après entraînement du méga-benchmark (export `mega_comparison_all_datasets3.html`, section *Explications RuleConEx*). Trois échantillons de test sont inspectés via `ruleconex.explain.explain_sample`.

6.1 Fusion des trois branches

Pour l'échantillon test #0 (vrai label `ops_pattern_12`), la prédiction fusionnée est correcte avec une confiance de 0,9948. Les poids appris de la fusion sont : HyConEx = 0,429 ; Règles = 0,429 ; Deep (TabResNet) = 0,143. Les trois branches convergent vers `ops_pattern_12` ; la branche HyConEx est la plus confiante (0,9999), suivie des règles (0,9578).

TABLE 6 – Prédictions par branche — échantillon test #0 (`u4k-r4k-auth11k`)

Branch	Prédiction	Confiance
HyConEx	<code>ops_pattern_12</code>	0,9999
Règles	<code>ops_pattern_12</code>	0,9578
Deep	<code>ops_pattern_12</code>	0,9947
Fusion	<code>ops_pattern_12</code>	0,9948

6.2 Règles IF-THEN extraites

L'hyperréseau de règles produit des clauses lisibles sur les littéraux one-hot `oh_*`. Chaque littéral `oh_k=+1` (resp. `=-1`) indique qu'une modalité de métadonnée utilisateur ou ressource est active (resp. inactive) dans l'encodage bipolarisé.

TABLE 7 – Top-8 règles décodées — échantillon test #0

ID	Conditions $\Rightarrow$ conclusion	Score
R17	<code>oh_8=+1 AND oh_32=+1 AND oh_55=-1 AND oh_62=-1 $\Rightarrow$ ops_pattern_6</code>	0,905
R01	<code>oh_118=-1 AND oh_15=+1 AND oh_39=-1 AND oh_29=+1 $\Rightarrow$ ops_pattern_11</code>	0,823
R06	<code>oh_100=+1 AND oh_124=+1 AND oh_82=+1 AND oh_76=+1 $\Rightarrow$ ops_pattern_1</code>	0,689
R37	<code>oh_97=-1 AND oh_75=-1 AND oh_22=-1 AND oh_149=-1 $\Rightarrow$ ops_pattern_9</code>	0,654
R25	<code>oh_8=+1 AND oh_5=+1 AND oh_43=+1 AND oh_99=+1 $\Rightarrow$ ops_pattern_3</code>	0,648
R39	<code>oh_83=+1 AND oh_21=+1 AND oh_26=+1 AND oh_138=+1 $\Rightarrow$ ops_pattern_12</code>	0,603
R32	<code>oh_100=-1 AND oh_112=-1 AND oh_120=-1 AND oh_10=-1 $\Rightarrow$ ops_pattern_5</code>	0,591
R16	<code>oh_54=-1 AND oh_99=-1 AND oh_20=-1 AND oh_34=-1 $\Rightarrow$ ops_pattern_8</code>	0,581

La règle R39 correspond exactement à la classe prédite (`ops_pattern_12`) pour cet échantillon. Les règles R17 et R25 pointent vers des classes alternatives (`ops_pattern_6` et `ops_pattern_3`) qui serviront de cibles contrefactuelles.

Importances locales. Les métadonnées les plus influentes pour cet échantillon sont `oh_90` (3,64), `oh_55` (3,63), `oh_22` (3,57), `oh_138` (3,49) et `oh_100` (3,45). Ces scores proviennent de la branche HyConEx (gradients locaux) et orientent la recherche de contrefactuels.

6.3 Contrefactuels générés

RuleConEx propose trois contrefactuels pour inverser la décision `ops_pattern_12` vers des classes alternatives à forte probabilité :

TABLE 8 – Contrefactuels — échantillon test #0

Cible	P_{CF}	# flips	Modifications principales
<code>ops_pattern_6</code>	1,000	7	<code>oh_16</code> , <code>oh_49</code> , <code>oh_55</code> , <code>oh_75</code> , <code>oh_115</code> : actif→inactif
<code>ops_pattern_3</code>	1,000	11	<code>oh_5</code> , <code>oh_16</code> , <code>oh_22</code> , <code>oh_49</code> , <code>oh_55</code> : actif→inactif
<code>ops_pattern_8</code>	0,9998	12	<code>oh_5</code> , <code>oh_16</code> , <code>oh_22</code> , <code>oh_29</code> , <code>oh_49</code> : actif→inactif

Lecture. Chaque contrefactuel indique quelles métadonnées modifier pour obtenir un autre profil d'accès (pattern d'opérations). Sur cet échantillon, les modifications affichées sont exclusivement des **désactivations** (*actif* → *inactif*) : la tête contrefactuelle combine une soustraction d'importances (`counterfactual_subtract`) et un mélange flip, ce qui tend à abaisser les activations one-hot ; seuls les flips aboutissant à une valeur binaire stricte sont reportés (seuil 0,5 dans `onehot_feature_flips`).

Validité globale sur le jeu. Sur l'ensemble du test `u4k-r4k-auth11k`, la validité contrefactuelle atteint **95,7 %** (tableau 5). Les trois échantillons illustrés (#0, #1, #2) sont tous correctement classés ; leurs contrefactuels atteignent $P_{CF} \geq 0,9998$.

7 Comparaison avec DLBAC α (référence du papier)

DLBAC α (Karimi et al., 2022, *Toward Deep Learning Based Access Control*) est le prototype historique : ResNet Keras, 4 sorties sigmoïdes (une par opération), perte *binary cross-entropy*. Les valeurs ci-dessous sont des **estimations visuelles** extraites des Figures 7 à 11 du papier ; pour chaque intervalle $[a, b]$, nous retenons la valeur centrale $(a + b)/2$.

7.1 DLBAC α vs. algorithmes ML classiques (F1)

TABLE 9 – F1 Score — ML vs DLBAC α (valeurs centrales des intervalles papier)

Jeu	SVM	RF	MLP	DLBAC α
Amazon Kaggle (<code>amazon1</code>)	0,895	0,940	0,875	0,955
Amazon UCI (<code>amazon2/3</code>)	0,450	0,700	0,500	0,730
Synthétiques (moyenne)	0,800	0,885	0,800	0,955

7.2 DLBAC α vs. policy mining

DLBAC α offre le meilleur équilibre global (F1 élevé, TPR > 0,95, FPR < 0,05) sur les jeux synthétiques, confirmant la supériorité du deep learning sur le policy mining classique.

7.3 Accuracy jointe : RuleConEx vs. DLBAC α

TABLE 10 – Policy mining vs DLBAC α — synthétiques (moyennes papier)

Métrique	XuStoller	Rhapsody	EPDE-ML	DLBAC α
F1 Score	0,525	0,625	0,885	0,955
FPR ↓	0,030	0,030	0,145	0,040
TPR ↑	0,125	0,525	0,850	0,970
Précision	0,450	0,600	0,850	0,950

TABLE 11: Accuracy jointe estimée — jeux synthétiques

Jeu	DLBAC α	RuleConEx	Δ
u4k-r4k-auth11k	0.9400	0.9758	+0.0358
u4k-r4k-auth21k	0.9400	0.8944	-0.0456
u4k-r4k-auth22k	0.9400	0.7033	-0.2367
u4k-r6k-auth28k	0.9400	0.8329	-0.1071
u4k-r7k-auth20k	0.9400	0.8849	-0.0551
u5k-r5k-auth12k	0.9400	0.9937	+0.0537
u5k-r5k-auth19k	0.9400	0.8989	-0.0411
u6k-r6k-auth32k	0.9400	0.9160	-0.0240
Moyenne (8 jeux)	0.9400	0.8875	-0.0525

Δ = RuleConEx – DLBAC α . Sur les jeux **faciles** (auth11k, auth12k), RuleConEx dépasse l’estimation papier ; sur les jeux **difficiles**, DLBAC α (ResNet profond, 60 époques) reste nettement au-dessus de RuleConEx (25 époques, architecture hybride).

7.4 Synthèse RuleConEx vs. DLBAC α

- **Prédiction** : accuracy moyenne quasi identique sur 11 jeux (0,9027 vs. 0,9016) ; DLBAC α domine sur les synthétiques difficiles, RuleConEx sur les jeux faciles et Amazon UCI (F1 joint) ;
- **Explicabilité** : DLBAC α requiert Integrated Gradients ou arbre post-hoc ; RuleConEx produit **règles IF-THEN** et **contrefactuels** natifs (validité 98,7 %) ;
- **Positionnement** : RuleConEx vise un **compromis** performance + explicabilité ; DLBAC α maximise la performance brute sur opérations binaires.

8 Temps d’entraînement

TABLE 12 – Temps moyen d’entraînement (secondes, 11 jeux)

Modèle	Temps moyen (s)
SVM	3,6
RandomForest	8,4
DecisionTree	29,6
MLP	36,8
HyConEx-Local	148,3
HyperLogic	234,4
RuleConEx	891,6

RuleConEx est le plus lent (~ 15 min/jeu en moyenne, jusqu’à 25 min sur Amazon), en raison de l’hyperméseau de règles, du Monte Carlo HyperLogic et de la perte contrefactuelle. Ce coût est le **prix de l’explicabilité** : seul RuleConEx fournit règles + CF dans le même entraînement.

Les modèles sklearn restent les plus rapides mais sont nettement moins précis sur les jeux synthétiques (accuracy ≈ 41 – 65 % vs. >89 % pour RuleConEx).

9 Analyse comparative

9.1 RuleConEx vs. MLP (meilleure baseline prédictive)

- **Accuracy** : écart moyen de 0.5 point (90.16 % vs. 90.66 %) en faveur du MLP :

- RuleConEx **égale ou dépasse** le MLP sur **u4k-r4k-auth11k** (accuracy) et reste à moins de 1 point sur la majorité des synthétiques ;
- Sur Amazon, RuleConEx obtient le **meilleur F1** sur deux jeux sur trois ;
- Le MLP ne fournit **aucune explication** ; RuleConEx ajoute validité CF $\approx 99\%$ sans sacrifice majeur de performance.

9.2 RuleConEx vs. HyConEx-Local

HyConEx-Local partage la branche d’importances/contrefactuels mais sans règles explicites. RuleConEx lui est **supérieur en accuracy moyenne** (+0,3 point) et **en F1 macro** (+1,8 points), grâce à la branche de règles. HyConEx-Local reste légèrement devant en AUC (+0,6 point) et **5× plus rapide**.

9.3 RuleConEx vs. HyperLogic

RuleConEx surpasse HyperLogic sur toutes les métriques prédictives (+7,6 points d’accuracy en moyenne). L’hyperréseau seul (HyperLogic) souffre sur les jeux difficiles (**auth22k** : 66,9 % accuracy) là où la fusion HyConEx + règles stabilise RuleConEx (70,3 %).

9.4 RuleConEx vs. modèles sklearn

Les arbres et forêts atteignent des performances correctes sur Amazon ($\approx 94\%$) mais **s’effondrent** sur les synthétiques multi-classes (accuracy 41–65 %). RuleConEx généralise nettement mieux sur les 16 patterns d’opérations jointes.

9.5 RuleConEx vs. DLBAC α (papier)

- **Accuracy globale** : quasi-équivalente (0,9016 vs. 0,9027 sur 11 jeux) ;
- **Jeux difficiles** : DLBAC α estimé à 94 % là où RuleConEx descend à 70–89 % (**auth22k**, **auth28k**) ;
- **Jeux faciles** : RuleConEx atteint 97–99 %, dépassant l’estimation DLBAC α (94 %) ;
- **Amazon UCI** : RuleConEx (94 % accuracy) surpasse nettement DLBAC α estimé (73 %) ;
- **Explicabilité** : seul RuleConEx fournit règles + CF sans post-traitement ; DLBAC α reste une boîte noire interprétée *a posteriori*.

10 Conclusion et perspectives

Les expériences du méga-benchmark confirment que **RuleConEx atteint un compromis favorable entre performance prédictive et explicabilité** :

1. **3^e rang** en accuracy moyenne (0,90 %), à 0,1 point de DLBAC α (papier) et du MLP ;
2. **Seul modèle** évalué sur la validité des contrefactuels ($\overline{\text{CF}} = 98,7\%$) ;
3. **Règles IF-THEN** extractibles pour l’audit de politiques d’accès (section 7) ;
4. **Contrefactuels** actionnables avec $P_{\text{CF}} \approx 1$ sur les échantillons illustrés ;
5. Sur les jeux difficiles, un ResNet DLBAC α entraîné 60 époques reste supérieur ; RuleConEx compense par l’explicabilité native et de meilleures performances sur jeux faciles et Amazon UCI.

Perspectives pour la suite du mémoire.

- Réentraîner RuleConEx avec plus d’époques sur les jeux difficiles pour rapprocher DLBAC α ;
- Affiner l’affichage des contrefactuels (proposer aussi des activations *inactif* $\rightarrow$ *actif*) ;
- Étendre l’évaluation à des métriques d’**interprétabilité humaine** (longueur des règles, couverture, stabilité) ;

- Rédiger le chapitre expérimental à partir de ce document et des figures exportées (`ranking_*.png`, `heatmap_*.png`).

Références internes :

- Notebook : `HyConEx_from_scratch/notebooks/mega_comparison_all_datasets.ipynb`
- Package : `HyConEx_from_scratch/mega_benchmark/`
- Module RuleConEx : `HyConEx_from_scratch/ruleconex/`
- Rapport d'avancement : `rapport_avancement_Erick_TSAFACK.pdf`
- Référence DLBAC α : Karimi et al. (2022), *Toward Deep Learning Based Access Control*, arXiv :2203.15124