

UNIVERSITÉ DE DSCHANG

Faculté des Sciences

Département de Mathématiques et Informatique

Unité de Recherche en Informatique Fondamentale, Ingénieries et Applications (URIFIA)

RAPPORT D'AVANCEMENT DE MÉMOIRE DE MASTER 2

Une approche d'explicabilité des modèles
d'apprentissage profond
pour le contrôle d'accès aux données et aux
traitements :
Les Self-Interpretable Neural Networks

Rédigé par :

TSAFACK NTEUDEM Erick

Matricule : CM-UDS-23SCI1383

Sous la supervision de :

Dr. AZANGUEZET QUIMATIO

Benoît Martin

Chargé de cours, Université de Dschang

Année Académique : 2025/2026

Table des matières

1	Contexte et Motivation	2
2	Problématique	3
3	Objectif Principal et Objectifs Spécifiques	3
3.1	Objectif principal	4
3.2	Objectifs spécifiques	4
4	Outils et Méthodes	4
4.1	Données	4
4.2	Outils et environnement technique	5
5	État de l’Art	5
5.1	DLBAC <i>Deep Learning Based Access Control</i>	5
5.2	HyConEx <i>Hypernetwork Classifier with Counterfactual Explanations</i> . .	5
5.3	HyperLogic <i>Enhancing Diversity and Accuracy in Rule Learning with HyperNets</i>	6
5.4	Limite de HyConEx et HyperLogic	7
6	Résultats Attendus	7
7	Références	7

I. Contexte et Motivation

L'essor des modèles d'apprentissage profond (*deep learning*) a révolutionné de nombreux domaines, notamment la cybersécurité, où ils sont de plus en plus employés pour le contrôle d'accès aux données. Cette tâche exige transparence et justification afin d'assurer la sécurité et la conformité réglementaire. Les modèles de deep learning, bien qu'efficaces pour traiter des données complexes, souffrent d'une opacité qualifiée de *boîte noire*, freinant leur adoption dans des contextes critiques où la responsabilité et la confiance sont primordiales.

Les approches classiques de contrôle d'accès telles que le DAC (*Discretionary Access Control*), le MAC (*Mandatory Access Control*), le RBAC (*Role-Based Access Control*) [5], le Or-BAC (*Organization-Based Access Control*) et le HOr-BAC (*Hierarchical Organization-Based Access Control*) [6] reposent sur des règles prédéfinies offrant une transparence naturelle mais une adaptabilité limitée face aux environnements dynamiques tels que les systèmes IoT ou le cloud. Ces modèles nécessitent une ingénierie manuelle coûteuse d'attributs et de politiques [1], ce qui les rend sujets aux erreurs humaines (*sur-provisionnement* ou *sous-provisionnement*) et difficiles à maintenir à grande échelle.

En revanche, les modèles d'apprentissage profond permettent une analyse en temps réel des accès grâce à leur capacité d'adaptation. Toutefois, leur adoption est entravée par leur opacité, rendant difficile l'audit et la justification des décisions. Dans ce cadre, les réglementations comme le Règlement Général sur la Protection des Données (RGPD) exigent une explicabilité stricte : l'article 22 stipule le droit à une explication des décisions automatisées. Cette contrainte met en lumière l'urgence de développer des méthodes d'intelligence artificielle explicable (XAI) capables de concilier performance et transparence[4].

Les approches post-hoc, telles que LIME et SHAP, offrent des solutions partielles pour pallier ce manque d'interprétabilité, mais présentent des limites importantes en termes de robustesse [8] : elles sont fragiles face aux attaques adversariales, peu fidèles au véritable fonctionnement du réseau, instables pour des entrées similaires, et computationnellement coûteuses [10]. Dans un système de décision critique comme le contrôle d'accès, ces limites peuvent engendrer une fausse confiance dans les décisions rendues.

Les réseaux neuronaux auto-interprétables (SINN *Self-Interpretable Neural Networks*) se positionnent comme une réponse prometteuse à ces défis, en intégrant l'interprétabilité

lité intrinsèque directement dans l’architecture du modèle, sans compromettre l’efficacité des prédictions. C’est dans ce contexte que s’inscrit le présent travail de recherche.

II. Problématique

Les systèmes de contrôle d’accès basés sur le deep learning présentent une triple tension : ils sont performants mais opaques, efficaces mais non conformes aux exigences réglementaires, et précis mais difficilement auditable. Cette situation soulève la question de recherche centrale suivante :

Comment développer une méthode d’explicabilité pour les modèles d’apprentissage profond utilisés dans le contrôle d’accès, assurant la fidélité des explications aux prédictions tout en répondant aux enjeux d’opacité, de biais et de conformité réglementaire ?

Trois obstacles principaux empêchent l’adoption des modèles de deep learning dans le contrôle d’accès :

- L’opacité des décisions, rendant difficile l’audit et la justification des refus ou autorisations d’accès ;
- Les exigences réglementaires, nécessitant des explications conformes au RGPD et auditable par des autorités compétentes ;
- Les risques de biais dans les données, pouvant entraîner des décisions inéquitables et discriminatoires.

Ces contraintes mettent en évidence le besoin urgent d’une architecture de contrôle d’accès basée sur le deep learning qui soit à la fois performante, transparente et actionnable. Le type d’explication idéal pour ce domaine est double : des explications sous forme de **règles logiques** (globales et auditable) et des **explications contre-factuelles** (locales et actionnables), répondant à la question “Que faut-il modifier pour obtenir ou refuser un accès ?”.

III. Objectif Principal et Objectifs Spécifiques

3.1 Objectif principal

L'objectif principal de ce travail est de concevoir un modèle d'apprentissage profond unifié pour le contrôle d'accès aux données et aux traitements, capable de produire simultanément des décisions précises et des explications interprétables, tant sous forme de règles logiques auditables que de contrefactuels actionnables en un seul passage avant (*single forward pass*).

3.2 Objectifs spécifiques

1. **Collecter et prétraiter les données pertinentes** : adapter le jeu de données Amazon, utilisé dans les travaux de DLBAC, pour refléter des scénarios réalistes de contrôle d'accès, en éliminant les bruits et en extrayant les caractéristiques pertinentes ;
2. **Explorer et analyser les méthodes existantes** : étudier la compatibilité des approches actuelles (DLBAC, HyConEx, HyperLogic) avec les exigences du contrôle d'accès, en identifiant leurs forces et leurs limites respectives ;
3. **Concevoir un modèle unifié (HyConLogic)** : intégrer dans une seule architecture un hypernetwork générateur de règles locales interprétables (inspiré de HyperLogic) et un générateur de contrefactuels plausibles (inspiré de HyConEx) ;
4. **Évaluer les performances et l'interprétabilité** : mesurer les performances du modèle proposé via des métriques standards (ROC AUC, F1-score, validité des contrefactuels, plausibilité) et les comparer aux approches classiques et aux méthodes de l'état de l'art ;
5. **Assurer la conformité réglementaire** : produire des explications lisibles par un humain, conformes aux exigences du RGPD, et exploitables pour l'audit des politiques d'accès.

IV. Outils et Méthodes

4.1 Données

Le jeu de données principal utilisé est le jeu de données Amazon, initialement employé par Nobi et al. dans leurs travaux sur DLBAC. Ce jeu de données contient des métadonnées brutes d'utilisateurs et de ressources (département, date d'entrée, logs, rôle, etc.) associées à des décisions d'accès (*grant/deny*). Le prétraitement comprend le nettoyage, la normalisation, la gestion des données manquantes, la discrétisation des attributs continus en intervalles (binarisation), et la gestion du déséquilibre de classes.

4.2 Outils et environnement technique

- **Langage de programmation** : Python ;
- **Framework principal** : PyTorch (pour l'implémentation des hypernetworks et l'accélération GPU) ;
- **Optimiseur** : Adam avec taux d'apprentissage adapté et scheduler cosinus ;
- **Métriques d'évaluation** : ROC AUC, F1-score, validité des contrefactuels, plausibilité (P.Plaus.), proximité (L1, L2), temps de calcul.

V. État de l'Art

L'état de l'art de ce travail s'articule autour de trois travaux fondateurs directement liés à la problématique : DLBAC, HyConEx et HyperLogic.

5.1 DLBAC *Deep Learning Based Access Control*

Nobi et al. (2022) [1] ont proposé DLBAC, une approche de contrôle d'accès fondée sur l'apprentissage profond qui répond aux limites des modèles classiques. L'idée centrale est de remplacer les règles d'accès par un réseau de neurones profond entraîné directement sur les métadonnées brutes des utilisateurs et des ressources, sans ingénierie manuelle d'attributs ni de politiques.

Le prototype DLBAC _{α} a été évalué sur deux jeux de données réels (dont Amazon) et huit jeux de données synthétiques de complexité croissante. DLBAC _{α} surpasse les méthodes de *policy mining* (XuStoller, Rhapsody, EPDE-ML) et les classifieurs ML classiques (RF, SVM, MLP) sur les scores F1, le taux de vrais positifs (TPR), et la généralisation. Il offre un meilleur équilibre entre sur-provisionnement et sous-provisionnement, et s'avère plus robuste face à la complexité des données.

Cependant, DLBAC reste un modèle opaque. Les auteurs proposent des pistes d'explicabilité post-hoc (*Integrated Gradients*, extraction d'arbres de décision approximatifs), mais celles-ci restent externes et présentent les limites inhérentes à toutes les méthodes post-hoc. DLBAC identifie lui-même l'explicabilité intrinsèque comme une direction future prioritaire, ce qui constitue précisément le cœur du présent travail.

5.2 HyConEx *Hypernetwork Classifier with Counterfactual Explanations*

HyConEx [2] est un modèle de classification conçu pour les données tabulaires, qui combine dans une seule architecture une prédiction de classe performante et la génération de contrefactuels plausibles pour toutes les classes alternatives, le tout produit en un

seul *forward pass*. Il s'agit de la première approche intégrant simultanément prédiction et explication contrefactuelle dans un même modèle.

Le mécanisme central repose sur un hypernetwork $H(x; \theta)$ qui, pour chaque entrée x , génère une matrice de poids W définissant un classifieur linéaire local. Les lignes de cette matrice servent à produire des contrefactuels par translation : $x' = x - W_m$. Trois conditions doivent être satisfaites pour chaque contrefactuel : il doit être correctement classifié dans la classe cible, rester proche de l'entrée originale, et être plausible (*in-distribution*), cette dernière condition étant assurée par un flux normalisant conditionnel.

Les expériences montrent que HyConEx atteint des performances compétitives en classification (AUROC jusqu'à 0.999 sur certains jeux de données) et génère des contrefactuels de qualité comparable aux méthodes externes (PPCEF, CEGP, CEM), tout en étant plusieurs ordres de grandeur plus rapide : 0.003 secondes contre plusieurs milliers de secondes pour les méthodes concurrentes. Le modèle gère également correctement les variables catégorielles grâce à un lissage softmax à basse température.

5.3 HyperLogic *Enhancing Diversity and Accuracy in Rule Learning with HyperNets*

HyperLogic [3], présenté à NeurIPS 2024 par Yang Yang, Wendi Ren et Shuang Li, est un cadre générique qui intègre des hypernetworks dans l'apprentissage différentiable de règles logiques IF-THEN. L'objectif est d'augmenter la diversité et la précision des règles apprises tout en préservant l'interprétabilité, en contournant les limitations structurelles des réseaux de règles classiques qui sont souvent trop rigides et peu expressifs.

L'hypernetwork de HyperLogic prend comme entrée un bruit gaussien ε et génère les poids $\theta = G(\varepsilon)$ du réseau principal (inspiré de DR-Net). Ce réseau principal est un réseau à deux couches : une couche *Rule*, qui apprend des conjonctions logiques via une approximation différentiable de la fonction indicatrice, et une couche *OR*, qui combine les règles de manière additive pondérée. En une seule session d'entraînement, HyperLogic peut générer jusqu'à 5 000 ensembles de règles candidats, parmi lesquels on sélectionne le meilleur selon des critères de performance et de concision.

La régularisation combine deux termes : une divergence KL pour encourager la diversité des ensembles de règles générés, et une norme ℓ_1 pour encourager la sparsité (règles concises) :

$$\ell_{\text{reg}} = \lambda_1 D_{\text{KL}}(\mu \parallel \mu_0) + \lambda_2 \mathbb{E}_{\mu} \left[\sum_{k=1}^K |u_k| \right]$$

Les expériences sur quatre jeux de données binaires (*magic*, *adult*, *house*, *heloc*) montrent que HyperLogic améliore les performances de DR-Net et surpasse les méthodes classiques (CG, BRS, RIPPER) en termes de précision, tout en réduisant la complexité des règles. L'analyse théorique établit que HyperLogic est un approximateur universel dans l'espace de Barron.

5.4 Limite de HyConEx et HyperLogic

Bien que **HyConEx** excelle dans la génération de contrefactuels locaux actionnables et qu'**HyperLogic** permette d'apprendre des règles interprétables et diversifiées, aucun des deux modèles ne produit simultanément ces deux types d'explications complémentaires. HyConEx ne génère pas de règles globales auditées, tandis qu'HyperLogic ne fournit pas d'explications contrefactuelles locales. C'est cette limite que notre modèle unifié **HyConLogic** vise à surmonter en intégrant ces deux approches au sein d'une seule architecture.

VI. Résultats Attendus

Au terme de ce travail, plusieurs types de résultats sont attendus sur les plans technique, évaluatif et pratique.

- Un modèle HyConLogic implémenté et fonctionnel, capable de produire en un seul *forward pass* : une décision d'accès, des règles logiques locales interprétables, et des contrefactuels valides et actionnables ayant des performances en classification comparables ou supérieures à DLBAC et aux approches classiques.
- La capacité de générer de multiples ensembles de règles candidats concises, lisibles par un humain en une seule session d'entraînement.
- Un pipeline de prétraitement adapté au jeu de données Amazon pour le contrôle d'accès.

VII. Références

Références

- [1] M. N. Nobi, R. Krishnan, Y. Huang, M. Shakarami, and R. Sandhu. Toward deep learning based access control. In *Proceedings of the ACM Conference on Computer and Communications Security*, 2022.
- [2] P. Marszałek, K. Książek, O. Furman, U. Movsum-zada, P. Spurek, and M. Śmieja. HyConEx : Hypernetwork classifier with counterfactual explanations for tabular data. *Neurocomputing*, 2026. <https://doi.org/10.1016/j.neucom.2026.132748>
- [3] Y. Yang, W. Ren, and S. Li. HyperLogic : Enhancing diversity and accuracy in rule learning with HyperNets. In *38th Conference on Neural Information Processing Systems (NeurIPS 2024)*, 2024.
- [4] B. Goodman and S. Flaxman. European union regulations on algorithmic decision-making and a “right to explanation”. *AI Magazine*, 38(3) :50–57, 2017.
- [5] R. S. Sandhu, E. J. Coyne, H. L. Feinstein, and C. E. Youman. Role-based access control models. *Computer*, 29(2) :38–47, 1996.
- [6] B. Azanguezet and P. Fotso. HOr-BAC : An access control based on hierarchical organizational. *International Journal of Computer Science and Information Technology Research*, 2016.
- [7] R. Guidotti. Counterfactual explanations and how to find them : Literature review and benchmarking. *Data Mining and Knowledge Discovery*, 38 :2770–2824, 2024.
- [8] C. Rudin. Stop explaining black box machine learning models for high stakes decisions and use interpretable models instead. *Nature Machine Intelligence*, 1(5) :206–215, 2019.
- [9] P. Wielopolski, O. Furman, J. Stefanowski, and M. Zięba. Probabilistically plausible counterfactual explanations with normalizing flows. In *European Conference on Artificial Intelligence*, 2024.
- [10] D. Slack, S. Hilgard, E. Jia, S. Singh, and H. Lakkaraju. Fooling LIME and SHAP : Adversarial attacks on post hoc explanation methods. In *Proceedings of the AAAI/ACM Conference on AI, Ethics, and Society*, pages 180–186, 2020.